

Modèles de régression gaussienne pour des distributions en entrée

49^e Journées de Statistiques


N. Venet^{*,*}, F. Bachoc^{*}, F. Gamboa^{*}, J.-M. Loubes^{*}

30 mai 2017, Avignon

^{*}CEA Tech, ^{*}Institut de Mathématiques de Toulouse


Le problème de régression sur des distributions

On dispose de n couples *entrées / sorties* $(\mu_i, y_i) \in \mathcal{P}(\mathbb{R}) \times \mathbb{R}$, et on cherche à associer une sortie à une distribution μ_{n+1} .




Le problème de régression sur des distributions

On dispose de n couples *entrées / sorties* $(\mu_i, y_i) \in \mathcal{P}(\mathbb{R}) \times \mathbb{R}$, et on cherche à associer une sortie à une distribution μ_{n+1} .



Le problème de régression sur des distributions

On dispose de n couples *entrées / sorties* $(\mu_i, y_i) \in \mathcal{P}(\mathbb{R}) \times \mathbb{R}$, et on cherche à associer une sortie à une distribution μ_{n+1} .



Nos motivations sont doubles : considérer des modèles dont les entrées sont


1. aléatoires ou
2. fonctionnelles (spectres, histogrammes, ...)
 - avec la restriction de positivité et de masse 1,
 - ... qui en contrepartie autorise l'intervention d'outils comme la *distance de Wasserstein*.

Plan de la présentation

1. Régression gaussienne
2. Noyaux sur l'espace de Wasserstein
3. Résultats asymptotiques pour l'EMV et la régression
4. Résultats numériques

Régression gaussienne

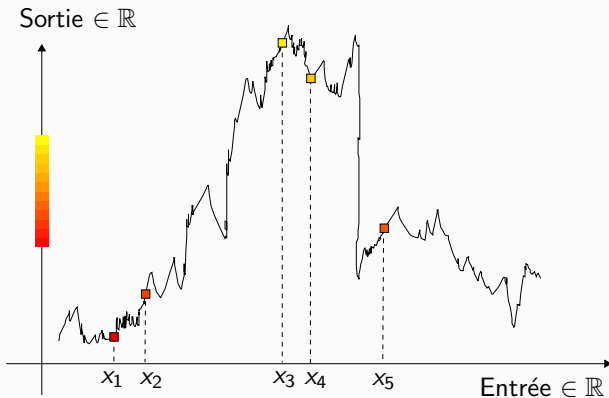
Régression gaussienne (Krigage)



On choisit un processus aléatoire $(Y_x)_{x \in \mathbb{R}}$ et on considère

$$\hat{Y}(x) := \mathbb{E}(Y_x | Y_{x_1} = y_1, \dots, Y_{x_n} = y_n)$$

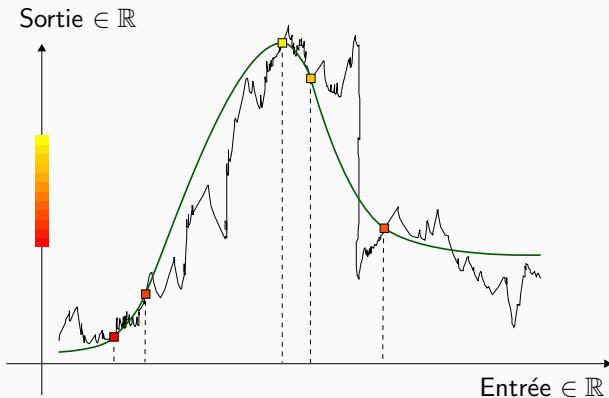
Régression gaussienne (Krigage)



On choisit un processus aléatoire $(Y_x)_{x \in \mathbb{R}}$ et on considère

$$\hat{Y}(x) := \mathbb{E}(Y_x | Y_{x_1} = y_1, \dots, Y_{x_n} = y_n)$$


Régression gaussienne (Krigage)



On choisit un processus aléatoire $(Y_x)_{x \in \mathbb{R}}$ et on considère

$$\hat{Y}(x) := \mathbb{E}(Y_x | Y_{x_1} = y_1, \dots, Y_{x_n} = y_n)$$

Régression gaussienne (Krigage)



Ici il faut un processus aléatoire $(Y_\mu)_{\mu \in \mathcal{P}(\mathbb{R})}$ pour considérer

$$\hat{Y}(\mu) := \mathbb{E}(Y_\mu | Y_{\mu_1} = y_1, \dots, Y_{\mu_n} = y_n)$$

Noyaux sur l'espace de Wasserstein


Distance de Wasserstein

La *distance de Wasserstein* entre deux probabilités μ et ν admettant des moments d'ordre deux est définie par :

\mathbb{R}

$$W_2(\mu, \nu) := \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^2 d\pi(x, y) \right)^{1/2},$$

où $\Pi(\mu, \nu)$ est l'ensemble des probabilités sur \mathbb{R}^2 de marginales μ et ν .



On obtient un espace métrique $\mathcal{W}_2(\mathbb{R})$.


Distance de Wasserstein

La *distance de Wasserstein* entre deux probabilités μ et ν admettant des moments d'ordre deux est définie par :

$$W_2(\mu, \nu) := \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^2 d\pi(x, y) \right)^{1/2},$$


où $\Pi(\mu, \nu)$ est l'ensemble des probabilités sur \mathbb{R}^2 de marginales μ et ν .

On obtient un espace métrique $\mathcal{W}_2(\mathbb{R})$.




Distance de Wasserstein

La *distance de Wasserstein* entre deux probabilités μ et ν admettant des moments d'ordre deux est définie par :



Distance de Wasserstein

La *distance de Wasserstein* entre deux probabilités μ et ν admettant des moments d'ordre deux est définie par :



$$W_2(\mu, \nu) := \left(\inf_{\pi \in \Pi(\mu, \nu)} \int_{\mathbb{R}^2} |x - y|^2 d\pi(x, y) \right)^{1/2},$$

où $\Pi(\mu, \nu)$ est l'ensemble des probabilités sur \mathbb{R}^2 de marginales μ et ν .

On obtient un espace métrique $\mathcal{W}_2(\mathbb{R})$.

Une remarque

Pour $\mu, \nu \in \mathcal{W}_2(\mathbb{R})$ et F_μ^{-1}, F_ν^{-1} les fonctions quantiles associées,

$$W_2(\mu, \nu) = \left(\int_{[0,1]} (F_\mu^{-1}(u) - F_\nu^{-1}(u))^2 du \right)^{1/2}. \quad (1)$$

- Ce couplage optimal spécifique à la dimension 1 permet l'évaluation numérique de la distance de Wasserstein.
- C'est aussi l'ingrédient central des preuves des Théorèmes 1 et 2.

Théorème 1 (Champs browniens fractionnaires)

Pour tout $0 \leq H \leq 1$ et $\sigma_0 \in \mathcal{W}_2(\mathbb{R})$,

$$K^{H,\sigma}(\mu, \nu) = \frac{1}{2} (W_2^{2H}(\sigma_0, \mu) + W_2^{2H}(\sigma_0, \nu) - W_2^{2H}(\mu, \nu)) \quad (2)$$

est une fonction de covariance sur $\mathcal{W}_2(\mathbb{R})$. De plus cette fonction est non-dégénérée si et seulement si $0 < H < 1$.

- On a un champ brownien fractionnaire indexé par $\mathcal{W}_2(\mathbb{R})$. Il est à accroissements stationnaires, nul en l'origine σ_0 .
- Le paramètre de Hurst H gouverne l'auto-similarité, la régularité des trajectoires et la mémoire à longue distance.

Théorème 2 (Processus stationnaires)

Pour $F : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ complètement monotone et $0 < H \leq 1$,

$$(\mu, \nu) \mapsto F(W_2^{2H}(\mu, \nu)) \quad (3)$$

est la fonction de covariance d'un processus gaussien stationnaire indexé par $\mathcal{W}_2(\mathbb{R})$.

- Rappelons que $F \in C^\infty(\mathbb{R}^+, \mathbb{R}^+)$ est complètement monotone si $(-1)^n F^{(n)}$ est à valeurs positives pour tout $n \in \mathbb{N}$.
- En particulier pour $\sigma^2, \ell > 0$ et $0 \leq H \leq 1$,

$$K_{\sigma^2, \ell, H}(\nu_1, \nu_2) = \sigma^2 \exp\left(-\frac{W_2(\nu_1, \nu_2)^{2H}}{\ell}\right) \quad (4)$$

est une covariance.

Résultats asymptotiques pour l'EMV et la régression

Conditions pour nos résultats i

Condition 1 (Cadre asymptotique “en expansion”)

On considère une matrice triangulaire de points d'observations de $\mathcal{W}_2(\mathbb{R})$ $\{\mu_1, \dots, \mu_n\} = \{\mu_1^{(n)}, \dots, \mu_n^{(n)}\}$ tels que pour tout $n \in \mathbb{N}$ et $1 \leq i \leq n$, μ_i est de support inclus dans $[i, i + K]$, où $K < \infty$ est fixe.

Condition 2 (Modèle paramétrique stationnaire)

Le modèle de fonctions de covariance $\{K_\theta, \theta \in \Theta \subset \mathbb{R}^p\}$ est tel que

$$\forall \theta \in \Theta, K_\theta(\mu, \nu) = F_\theta(W_2(\mu, \nu)) \text{ et } \sup_{\theta \in \Theta} |F_\theta(t)| \leq \frac{A}{1 + |t|^{1+\tau}},$$

avec $A < \infty$ et $\tau > 1$ des constantes.

Conditions pour nos résultats ii

Condition 3 (Cas “bien spécifié”)

Nous disposons d'observations $y_i = Y(\mu_i)$, $i = 1, \dots, n$ du processus aléatoire gaussien Y , centré et de covariance K_{θ_0} pour un $\theta_0 \in \Theta$.

Condition 4 (Non-dégénérescence asymptotique)

La suite de matrices $R_\theta = (K_\theta(\mu_i, \mu_j))_{1 \leq i, j \leq n}$ est telle que

$$\lambda_{\inf}(R_\theta) \geq c$$

pour une constante $c > 0$, où $\lambda_{\inf}(R_\theta)$ désigne la plus petite valeur propre de R_θ .

Condition 5

$$\forall \alpha > 0, \liminf_{n \rightarrow \infty} \inf_{\|\theta - \theta_0\| \geq \alpha} \frac{1}{n} \sum_{i,j=1}^n [K_\theta(\mu_i, \mu_j) - K_{\theta_0}(\mu_i, \mu_j)]^2 > 0.$$

Théorème 3 (Consistance de l'EMV))

Sous les conditions 1 à 5 l'estimateur par maximum de vraisemblance est consistant, c'est-à dire :

$$\hat{\theta}_{ML} \xrightarrow[n \rightarrow \infty]{\mathbb{P}} \theta_0.$$

Condition 6 (Régularité du modèle)

- $\forall t \geq 0$, $F_\theta(t)$ est \mathcal{C}^1 en θ et vérifie

$$\sup_{\theta \in \Theta} \max_{i=1, \dots, p} \left| \frac{\partial}{\partial \theta_i} F_\theta(t) \right| \leq \frac{A}{1 + t^{1+\tau}}, \text{ où } A, \tau \text{ sont définis dans la Condition 2.}$$

- Pour tout $t \geq 0$, $F_\theta(t)$ est \mathcal{C}^3 en θ et $\forall q \in \{2, 3\}$,
 $\forall i_1 \dots i_q \in \{1, \dots, p\}$,

$$\sup_{\theta \in \Theta} \max_{i=1, \dots, p} \left| \frac{\partial}{\partial \theta_{i_1}} \dots \frac{\partial}{\partial \theta_{i_q}} F_\theta(t) \right| \leq \frac{A}{1 + |t|^{1+\tau}}.$$

- $\forall (\lambda_1 \dots, \lambda_p) \neq (0, \dots, 0)$,

$$\liminf_{n \rightarrow \infty} \frac{1}{n} \sum_{i,j=1}^n \left(\sum_{k=1}^p \lambda_k \frac{\partial}{\partial \theta_k} K_{\theta_0}(\mu_i, \mu_j) \right)^2 > 0.$$

Théorème 4

Soit M_{ML} la matrice de taille $p \times p$ définie par

$$(M_{ML})_{i,j} = \frac{1}{2n} \text{Tr} \left(K_{\theta_0}^{-1} \frac{\partial K_{\theta_0}}{\partial \theta_i} K_{\theta_0}^{-1} \frac{\partial K_{\theta_0}}{\partial \theta_j} \right).$$

Sous les conditions 1 à 6, l'estimateur par maximum de vraisemblance est asymptotiquement normal. Plus précisément :

$$\sqrt{n} M_{ML}^{1/2} \left(\hat{\theta}_{ML} - \theta_0 \right) \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, I_p).$$

De plus

$$0 < \liminf_{n \rightarrow \infty} \lambda_{\min}(M_{ML}) \leq \limsup_{n \rightarrow \infty} \lambda_{\max}(M_{ML}) < +\infty.$$

Théorème 5

Sous les conditions 1 à 6, l'estimateur par Krigeage sous $\hat{\theta}_{ML}$ est asymptotiquement optimal :

$$\forall \mu \in \mathcal{W}_2(\mathbb{R}), \quad \left| \hat{Y}_{\hat{\theta}_{ML}}(\mu) - \hat{Y}_{\theta_0}(\mu) \right| = o_{\mathbb{P}}(1).$$

Résultats numériques

Performances sur des données simulées

- On note $m_k(\nu)$ le k -ième moment de ν et considère la fonction

$$F : \mathcal{W}_2(\mathbb{R}) \rightarrow \mathbb{R}$$

$$F(\nu) = \frac{m_1(\nu)}{0.05 + \sqrt{m_2(\nu) - m_1(\nu)^2}}, \quad (5)$$

qu'on va chercher à interpoler.

Performances sur des données simulées

- On note $m_k(\nu)$ le k -ième moment de ν et considère la fonction

$$F : \mathcal{W}_2(\mathbb{R}) \rightarrow \mathbb{R}$$

$$F(\nu) = \frac{m_1(\nu)}{0.05 + \sqrt{m_2(\nu) - m_1(\nu)^2}}, \quad (5)$$

qu'on va chercher à interpoler.

- On génère ν_1, \dots, ν_{100} qui sont des gaussiennes de moyennes et de variances tirées uniformément, perturbées aléatoirement afin d'exhiber des irrégularités.

Performances sur des données simulées

- On note $m_k(\nu)$ le k -ième moment de ν et considère la fonction

$$F : \mathcal{W}_2(\mathbb{R}) \rightarrow \mathbb{R}$$

$$F(\nu) = \frac{m_1(\nu)}{0.05 + \sqrt{m_2(\nu) - m_1(\nu)^2}}, \quad (5)$$

qu'on va chercher à interpoler.

- On génère ν_1, \dots, ν_{100} qui sont des gaussiennes de moyennes et de variances tirées uniformément, perturbées aléatoirement afin d'exhiber des irrégularités.
- Maximum de vraisemblance sur $\hat{\sigma}^2, \hat{\ell}, \hat{H}$ pour le modèle gaussien paramétrique

$$K_{\sigma^2, \ell, H}(\nu_1, \nu_2) = \sigma^2 \exp \left(-\frac{W_2(\nu_1, \nu_2)^{2H}}{\ell} \right). \quad (6)$$

Performances sur données simulées

- On évalue la méthode sur un jeu de données test $(\nu_{t,i})_{i=1}^{500}$ généré de la même manière que les ν_i ,

Performances sur données simulées

- On évalue la méthode sur un jeu de données test $(\nu_{t,i})_{i=1}^{500}$ généré de la même manière que les ν_i , avec les critères :

$$RMSE^2 = \frac{1}{500} \sum_{i=1}^{500} \left(F(\nu_{t,i}) - \hat{F}(\nu_{t,i}) \right)^2,$$

$$CIR_{\alpha} = \frac{1}{500} \sum_{i=1}^{500} \mathbf{1} \left\{ \left| F(\nu_{t,i}) - \hat{F}(\nu_{t,i}) \right| \leq q_{\alpha} \hat{\sigma}(\nu_{t,i}) \right\}.$$

Performances sur données simulées

- On évalue la méthode sur un jeu de données test $(\nu_{t,i})_{i=1}^{500}$ généré de la même manière que les ν_i , avec les critères :

$$RMSE^2 = \frac{1}{500} \sum_{i=1}^{500} \left(F(\nu_{t,i}) - \hat{F}(\nu_{t,i}) \right)^2,$$

$$CIR_{\alpha} = \frac{1}{500} \sum_{i=1}^{500} \mathbf{1} \left\{ \left| F(\nu_{t,i}) - \hat{F}(\nu_{t,i}) \right| \leq q_{\alpha} \hat{\sigma}(\nu_{t,i}) \right\}.$$

modèle	RMSE	$CIR_{0.9}$
“Wasserstein”	0.094	0.92
“Legendre” ordre 5	0.49	0.92
“Legendre” ordre 10	0.34	0.89
“Legendre” ordre 15	0.29	0.91
“PCA” ordre 5	0.63	0.82
“PCA” ordre 10	0.52	0.87
“PCA” ordre 15	0.47	0.93

Merci pour votre attention.



F. Bachoc.

Asymptotic analysis of the role of spatial sampling for covariance parameter estimation of Gaussian processes.

Journal of Multivariate Analysis, 125 :1–35, 2014.



F. Bachoc, F. Gamboa, J.-M. Loubes, and N. Venet.

Gaussian process regression model for distribution inputs.

arXiv preprint arXiv :1701.09055, 2017.



C. Berg, J. P. R. Christensen, and P. Ressel.

Harmonic analysis on semigroups.

Springer-Verlag, 1984.



J. Istas.

Manifold indexed fractional fields.

ESAIM Probab. Stat., 16 :222–276, 2012.



N. Venet.

Nonexistence of fractional brownian fields indexed by cylinders.

arXiv preprint, 2016.



N. Venet.

On the existence of fractional brownian fields indexed by manifolds with closed geodesics.

arXiv preprint, 2016.



C. Villani.

Optimal transport : old and new, volume 338.

Springer Science & Business Media, 2009.

Avis de recherche :

Jeux de données spatiales sur le cylindre

$$\mathbb{S}^1 \times \mathbb{R}.$$